Entrainer et exposer un modèle d’IA existant

Contraintes générales pour tous les projets :

- Un environnement virtuel (`.venv`) pour isoler les dépendances.
- Un fichier `requirements.txt` doit lister toutes les dépendances du projet.
- Un fichier `README.md` doit décrire le projet, et les instructions d'installation.
- Un fichier `.ignore` doit refuser le versionnage du `.venv`.

Installation des Bibliothèques et Préparation du Modèle :

Création d'un environnement virtuel :

- Ouvrez votre terminal ou invite de commandes.
- Exécutez la commande : `python -m venv .venv`

Activation de l'environnement virtuel :

- Sous Windows : `.venv\Scripts\activate`
- Sous macOS/Linux : `source .venv/bin/activate`

Installation des dépendances :

- Assurez-vous d'être dans le répertoire du projet.
- Exécutez la commande : `pip install -r requirements.txt`
- Sinon installer les bibliothèques vous même

Bibliothèques :

- `pyplot`
- `pandas`
- `matplotlib ou seaborn`
- `scikitlearn`
- `tensorflow`
- `loguru`
- `pytest`
- `mlflow`

Énoncé :

- Ce projet vise à développer une application d'analyse prédictive du montant des prêts basée sur un modèle d'intelligence artificielle.
- L'objectif est de créer un système robuste capable de prédire le montant du prêt en fonction de caractéristiques socio-démographiques et économiques d'individus.
- L'architecture du projet sera modulaire et évolutive, séparant la logique de traitement des données de la partie modélisation.
- L'application permettra de tester différentes configurations de modèles et de comparer leurs performances sur des jeux de données distincts, afin d'évaluer leur capacité à généraliser sur de nouvelles données.

Actions à mener

Source :

Faire un clone git (option proposé au démarrage de vscode) de

https://github.com/twentz29/OPCO-ATLAS-Module-1-Brief-1

Installation de l'environnement :

Suivre les instructions détaillées fournies précédemment pour créer un environnement virtuel Python (**.venv**) et y installer toutes les dépendances nécessaires depuis le fichier `requirements.txt`.

Prendre en main le code de votre prédécesseur

Lire le README.md.

Explorer et faire tourner le code, n'allez pas dans le détail des différents modules mais comprenez l'architecture en couche proposée ainsi que le but des fonctions proposées.

- Documentez les fonctions avec des docstring

- définir les inputs/outputs des fonctions
- définir rapidement le but des fonctions

Le code de votre prédécesseur affiche des métriques et des courbes.

Faites une recherche (veille technologique courte) pour comprendre ces 3 métriques ainsi que les deux courbes affichées

Une fois cette opération faite venez me voir pour discuter du but des fonctions et voir votre compréhension globale du projet.

Une fois le code compris, commencez vos expériences.

Vous avez accès à un préprocesseur et un modèle déjà entraîné.

Vous avez accès à deux jeux de données, le premier **`df_old.csv`** à permis d'entraîner le premier modèle, vous avez une version mise à jour des données dans **`df_new.csv`**.

Vous pouvez :

- le refaire, entraîner un modèle vierge à partir de ces données
- évaluer le nouveau jeu de données avec cet ancien modèle
- re entraîner ce vieux modèle avec les anciennes ou nouvelles données
- créer un nouveau modèle (vierge) et l'entraîner avec ces nouvelles données
- mesurer les performances de ce nouveau modèle avec les anciennes données

Si vous entraînez plusieurs fois un modèle avec les mêmes données, qu'êtes-vous en train de faire ?

Monitorer les performances[1]

Utilisez vos connaissances de MLFlow pour monitorer les modèles

Une fois cette opération faite venez me voir pour discuter.